

作业题 6

实验环境：

- 开发环境：Python 编程语言
- 运行环境：Windows11
- 工具：Visual Studio Code
- 库：numpy, Matplotlib

作业题目：

对两个函数线型（Gauss 分布和 类 Lorentz 型分布），设其一为 $p(x)$ ，另一为 $F(x)$ ，其中常数 c ，用舍选法对 $p(x)$ 抽样。将计算得到的归一化频数分布直方图与理论曲线 $p(x)$ 进行比较，讨论差异，讨论抽样效率

理论计算：

取类洛伦兹分布作为 $p(x)$ ，取高斯分布作为 $F(x)$ ，

任取常数 $a \neq b \neq 1$ （此方法对任意 a, b 通用）

$$\text{选定 } b \text{ 以后，归一化 } p(x) = \frac{\sqrt{2^4 b}}{\pi} \frac{1}{1 + bx^4}$$

此时应该找到一个 c 使得 $cF(x) \geq p(x)$ 恒成立，亦即 $c \geq \max \frac{p(x)}{F(x)}$

很难直接找到 c ，而且由于在 x 趋于无穷时， $F(x)$ (指数)趋于0的速度更快，这样的 c 实际不存在

因此只能保证我们所抽样的所有点满足 $c \geq \max \frac{p(x)}{F(x)}$ ，

于是可以采抽样和取 c 值同步进行的方法，如下

1、取 $c = 1$ ，定义数组 $p[]$

2、使用变换采样法(boxer - muller法)抽取一个符合 $F(x)$ (高斯分布)的采样点 x

3、比较 c 和 $\frac{p(x)}{F(x)}$ ，若 c 更大，进入第4步；

否则，取 $c = \frac{p(x)}{F(x)}$ ，并将 $p[]$ 数组中所有使 $cF(x) \leq p(x)$ 的点去掉，

然后进入第4步

4、抽取一个 $[0,1]$ 均匀分布的采样点 ξ ，若 $\xi * cF(x) \geq p(x)$ ，将 x 添加入数组 $p[]$ ；

否则不添加

5、重复2至4步，直到 $p[]$ 取到足够多的点， $p[]$ 就是满足 $p(x)$ 分布的采样

可以看到，此算法在不断更新 c 和 $p[]$ ，使得 $cF(x) \geq p(x)$ 恒成立，

因此无论 a, b 取何值，都能算出结果

可以说，此算法是对总抽样点数 N 自适应的，

总点数 N 较小时，使 c 取很大值的 x 很难被抽到，因此采样效率较高

总点数 N 较大时，使 c 取很大值的 x 可能会被抽到，使得采样效率减小，

但这是必要的牺牲，因为 N 大时，一些在边缘的值应该被抽到

采样效率应该这么理解：

假如 c 的初始值已经能满足 $cF(x) \geq p(x)$ 恒成立了，而且 $F(x), p(x)$ 已经归一化，

那么理论采样效率为： $\frac{1}{c}$

但这是 c 在最后一次更新后的理论效率，算上前面的被舍弃的抽样，

理论效率要远小于 $\frac{1}{c}$

因此此算法的采样效率随 N 增大急剧减小

理论上抽样效率小于 $1/c$ （程序中的 $F(x)$ 已经归一化了）

算法流程：

主要流程已经在理论计算中给出，此处只说明程序运行后输出结果的格式：

1. 每次 c 更新后都将新的 c 打印出来

2. 主体循环结束后打印总的抽样点数、被最终采用的点数、最终的 c 值
3. 绘制频率分布直方图，并且同时画出 $F(x)$, $p(x)$ 的图像（散点）

实验结果和结论：

取总点数分别为 1000, 5000, 10000, 15000, 20000（无图片）。结果如图 1-4

最终打印结果：

$N=1000$ 时

1844 1000 1.6211009345339606

效率： $1000/1844=0.54$

$1/c=1/1.6211=0.62$

$N=5000$ 时

168888 5000 28.71203516554577

效率： $5000/168888=0.030$

$1/c=1/28.712=0.035$

$N=10000$ 时

308823 10000 28.71203516554577

效率： $10000/308823=0.032$

$1/c=1/28.712=0.035$

$N=15000$ 时

3679023 15000 99.85447346260264

效率： $15000/3679023=0.0041$

$1/c=1/99.854=0.01$

$N=20000$ 时

97763797 20000 3493.142948317334

效率： $20000/97763797=0.0002$

$1/c=1/3493=0.00029$

由图可知，当 $N=5000$ 以后，频率分布直方图和原图像已经很相近了，但在 $x=0$ 处相对有较大的偏差。

由打印结果可知，实际抽样效率的确小于 $1/c$ ，但基本不超过一个数量级。而且随着 N 增大，效率也显著下降，这与 $F(x)$ 和 $p(x)$ 在 x 较大时比值较大有关。




图 1 1000 个点




图 2 5000 个点




图 3 10000 个点




图 4 15000 个点